[양식1] 오픈소스프로젝트 중간보고서

오픈소스프로젝트 중간보고서

학생 팀별 작성용

과제 수행원 현황						
수행 학기	■ 2026년 9월 ~ 2026년 12월					
프로젝트명	■ 음성인식 기반 공연 자막 오퍼레이터 작업 보조 인터페이스					
팀명	■ Helper (03팀)					
	학과	**학번**	**성명**	**성별**	**연락처**	**E-mail**
팀장	통계학과	2023113414	김소영	여	010-4618-1750	withkyu4045@naver.com
팀원	통계학과	2022110457	강지호	남	010-7440-2310	wlgh022111@naver.com
팀원	통계학과	2024110391	이동은	여	010-9315-7148	dongeun0705@naver.com
지도교수	**교과목명**	■ 오픈소스소프트웨어프로젝트				
	소속	■ 동국대학교 SW교육원 / 융합소프트웨어 연계전공				
	성명	■ 이길섭 교수				

프로젝트

프로젝트 개요

☻ 프로젝트에 대한 개요 설명 :

- **주제:** 공연 음성과 사전 제작 대본을 비교해, 자막 오퍼레이터에게 배우가 지금 대본의 어디를 말하고 있는지와 대본 이탈·복귀 위치를 보조 화면에 표시하는 소프트웨어. 사회혁신가 ㈜오롯플래닛(공연 자막 서비스 '유니스텝' 운영)이 제안한 'AI 오퍼레이터 작업 보조 인터페이스' 과제에서 출발함[13].
- **제작 목적:** 애드리브·대사 누락으로 오퍼레이터가 대본 위치를 놓치는 순간에 배우가 돌아온 큐 번호를 알려, 이탈 뒤 올바른 자막이 다시 송출되기까지의 시간을 줄이는 것.
- **주요 고객층:** 고객은 ㈜오롯플래닛, 1차 사용자는 유니스텝 자막 오퍼레이터(공연별로 투입되는 프리랜서), 최종 수혜자는 자막석 관객(외국인 85~90% 이상, 청각장애인).
- **문제 정의(한 문장):** 애드리브·대사 누락·반복 등으로 실제 발화가 사전 대본과 달라지면, 공연당 약 1,000~1,500개의 자막 큐를 수동으로 송출하는 유니스텝 오퍼레이터는 현재 위치를 다시 찾는 데 시간이 걸려 자막이 비거나 최대 30초 늦어지고, 그 결과 외국인·청각장애인 관객은 공연의 같은 순간을 놓침.
- **해결 방향:** 음성인식 결과를 대본 문장과 비교해 배우가 말하고 있는 현재 큐를 추적하고, 애드리브·대사 누락으로 대본을 벗어나는 순간을 감지해 대본으로 돌아온 큐 번호를 표시함. 결과는 오퍼레이터용 보조 화면에만 나타나며, 송출은 오퍼레이터가 기존 송출 프로그램에서 함.
- **최종 결과물:** 오퍼레이터 노트북에서 실행되는 오픈소스 보조 소프트웨어(대본 추적·이탈

	감지 엔진, 보조 화면, 회차 로그). 기존 송출 프로그램은 변경하지 않음. GitHub에 공개함. ▪ **학기 목표:** 1단계(대본 위치 추적·이탈 감지·복귀 큐 표시)를 완성해 중간 발표와 성과 발표에서 공개 공연 영상으로 시연함. 2단계(송출 중인 큐와 비교)는 송출 프로그램 연동 방식이 확인되면, 3단계(오퍼레이터가 켠 구간 자동 전진)는 연동과 사회혁신가 동의가 모두 있을 때 진행함. ▪ **함께하는 분들:** 오롯플래닛 황운주 팀장(사회혁신가), 카카오 멘토 이민정(카카오스타일, 기획) · 이상은(카카오페이, 모바일 개발). ▪ **중간 진행 상황(11/3):** 1단계 MVP가 동작함. 공연 녹음(3.5분)을 실제 속도로 재생해 잰 위치 정확도는 90.7%(앞뒤 1큐 허용), 이탈을 넣은 녹음에서는 9건 중 6건을 잡았고 잘못된 알림은 없었음. 모두 녹음으로 확인한 결과이고, 실제 공연장에서는 아직 써 보지 않음(11/13에는 오롯플래닛 공연 현장 체험으로 실제 송출을 보러 감). ▪ **제안 이후 바뀐 점:** 음성인식은 Google Chirp 3(API)로 먼저 만들고 로컬 모델(whisper)을 같이 시험 중. 대본 줄을 눌러 위치를 바로잡는 기능을 더했고, 회차 기록은 SQLite 대신 JSONL 파일로 남김. 보조 화면에 송출 버튼을 두어, AI가 추천한 큐와 애드리브 임시 자막을 오퍼레이터가 확인한 뒤 송출함(자동 송출 없음, 실제 관객 송출은 송출 프로그램 연동 후). ▪ **피드백 반영:** 제안 발표 때 질문 중 표현 차이("반갑습니다"·"반가워요")는 자모 단위 비교로, 공연장 인터넷 문제는 로컬 모델 시험으로 대비함. 10/27 중간 체크인에서 사회혁신가가 요청한 네 가지(로컬 모델 병행, 애드리브도 로컬로 검증, 기존 시스템에 '지금 몇 번째 자막'을 넘기는 결합, 공개 공연 영상으로 시험)는 일정에 넣음(그림 7).
추진 배경 (자료조사 및 요구분석)	**☻ 1. 개발 배경 및 필요성 :** **(1) 고객과 사용자** ▪ **고객(사회혁신가):** ㈜오롯플래닛. 2020년 창업한 소셜벤처로 정규 인력 3명. 청각·연령·언어 장벽 없는 문화 접근성을 미션으로 연 800편 이상의 영화·OTT 배리어프리 자막을 만들고 웹 기반 자원봉사 자막 제작 플랫폼을 운영함[22][23]. 2024년 여름 공연 다국어 자막 서비스 유니스텝[24]을 시작해 2년간 30편 이상의 공연에 자막을 제공했고[14], 대극장 공연과 지방 투어로 확장 중임[1][2]. ▪ **1차 사용자(오퍼레이터):** 공연별로 투입되는 프리랜서. 공연 영상과 자막으로 미리 연습한 뒤 현장 노트북으로 자막을 송출함[1]. 공연과 캐스트가 3~4개월마다 바뀌어 애드리브에 익숙하지 않은 '신규 투입' 상태가 반복되므로, 본 프로젝트는 신규 오퍼레이터를 핵심 사용자로 둠((3) 참고) ▪ **수혜자(관객):** 자막석 이용자는 외국인이 85~90% 이상이며(중국인 약 80%, 일본인 약 10%), 청각장애인 관객은 주로 사회공헌 공연 회차·커뮤니티 행사로 관람함[1]. **(2) 현재 업무 흐름** 대본(PDF·Word) 수령 → 자체 파이썬 코드로 배리어프리 자막 형식 변환 → AI 번역과 사람 검수 → 공연당 약 1,000개 ~ 1,500개의 자막 큐 완성 → 공연 당일 객석 뒷줄에 기기 설치 → **오퍼레**

이터가 큐를 한 줄씩 수동 송출(최대 5개 언어 동시). 제작·번역은 이미 효율화되어 있고, 송출만 전부 수작업으로 남아 있음.

(3) 현장에서 확인한 문제 (필드트립 인터뷰, 2026.9.15)[1]

- **연속 수동 송출의 피로:** 2시간 이상 매 대사마다 '지금 넘길 것인가'를 판단해야 함. 사회혁신가는 '오퍼레이터의 일을 어떻게 줄일 것인가'를 가장 중요한 문제로 꼽음.
- **대본 이탈 시 자막 공백:** 애드리브는 배우 조합마다 달라 미리 등록하기 어렵고, 예상 밖 애드리브는 빈 자막으로 처리함. 자막 지연은 보통 2~3초, 심하면 30초. 오롯플래닛 대표도 배우의 즉흥 애드리브를 자막에 반영하는 방법을 공연 자막의 주요 과제로 꼽음[3].
- **반복되는 학습 비용:** 오퍼레이터는 4~5회차가 지나야 애드리브에 익숙해짐. 공연은 3~4개월 단위로 바뀌고 캐스트도 바뀌어 이 과정이 계속 반복됨.
- **자동화 시도의 좌절:** 과거 음성인식 적용은 "반갑습니다"와 "반가워요" 같은 표현 차이를 인식하지 못해 중단됨. 오류가 한 번도 허용되지 않아 완전 자동화는 신뢰하지 않으며, 사람이 최종 결정하는 보조 방식을 원함("애드리브 문제만 해결돼도 만족").

(4) 사업 구조(사회혁신가 서면 답변, 2026.9)[1]

* 매출은 좌석 수수료로 한정되고 비용은 오퍼레이터 인력에 몰려 있어, 사람을 더 투입하는 방식으로는 확장이 어려움. 새로 투입된 오퍼레이터가 빨리 제 몫을 하도록 돕는 도구가 비용과 인력 병목을 함께 줄임.

(5) 필요성

- 자막은 이미 만들어져 있는데, 그것을 제때 띄우는 일은 오퍼레이터 한 사람의 기억과 집중에 맡겨져 있음. 특히 배우가 대본을 벗어났다 돌아오는 순간에는 돌아온 위치를 확인할 수단이 없고, 이 부담은 공연·캐스트가 바뀔 때마다 새로 투입된 오퍼레이터에게 되풀이됨.
- 인력 추가는 비용 구조상 한계가 있고((4) 참고), 완전 자동화는 사회혁신가가 받아들일 수 없음. 따라서 송출 판단은 오퍼레이터에게 두고, 대본 위치 찾기만 돕는 보조 기술이 필요함.

☻ 2. 선행기술 및 사례 분석 :

(1) 국내 사례

- **AI 자막안경 '아울'(엑스퍼트아이엔씨):** 국립극단(2024), 샤롯데씨어터 <킹키부츠>(2025.12), 충무아트센터 <한복 입은 남자>(2025.12), 세종문화회관 <베토벤>(2026.6) 등에 도입됨[4][5][17][6]. 배우의 실시간 음성을 사전 등록된 대본과 비교해 AR 안경 렌즈에 다국어 자막을 표시하며[16], 무인 자동 송출을 지원함[18]. 렌즈에만 자막이 떠 주변 관객에게 빛 방해가 없는 것이 장점.
  - 한계: 자동 송출 시 인식 지연·오류가 관객 화면에 그대로 드러남. 사회혁신가에 따르면 외국인 관객 리뷰에서도 딜레이가 지적됐으며, "아울을 쓰더라도 오퍼레이터가 수동으로 송출하게 할 것"이라고 답함[1]. 수동으로 운영할 때 대본 이탈·복귀를 알려 주는 기능은 공개 자료에서 확인되지 않음.

- **국회 AI 음성인식 생중계 자막(국회사무처·ETRI):** 2023년 2월부터 상임위원회 인터넷 의사중계에 실시간 AI 자막을 제공함. 국회법 제149조제3항(장애인 정보 제공)에 근거하며, 발성 후 1~2초 안에 자막을 표출함[9].
  - 한계: 음성인식 결과를 그대로 자막으로 쓰므로 인식 정확도가 곧 자막 품질이 됨. 대본이 없는 회의에 맞는 방식이고, 대본 이탈 감지나 복귀 위치 표시는 없음. ETRI 한국어 음성인식은 본 프로젝트 음성인식 비교 후보에 넣어 시험함(10/12, 44%).

(2) 해외 사례

- **영국 국립극장 Smart Caption Glasses (2018.10~):** 음성 추적(speech-following) 소프트웨어가 조명·음향 큐를 기준점 삼아 공연 진행을 따라가며 자막을 안경으로 보냄. 자막 제공 회차 비율을 **5%에서 80%(연 약 800회)**로 늘림[7].

(3) 유사 연구와 관련 특허

- **관련 연구:** 악보 추적(Dannenberg, 1984)과 온라인 동적 시간 정합(Dixon, 2005)은 실시간 입력을 미리 알려진 순서열에 맞추는 방법으로 대본 추적과 원리가 같음[11]. Whisper(Radford 외, 2022)는 공개 다국어 음성인식 모델이고[10], 실시간 문자 통역에서 자동 인식 결과를 사람이 교정하는 연구는 '자동화 + 사람의 최종 판단' 구조의 근거가 됨[12].
- **특허 US 10,726,842 B2 'Caption delivery system'(Royal National Theatre):** 음성인식으로 대사를 대본 항목과 비교하고 무대 이벤트 메타데이터를 함께 써서 자막을 전달함[8]. 본 프로젝트와 개념이 가장 가까워 청구항을 비교함(팀 자체 비교, 법률 검토 아님). 독립항(1, 15)은 무대 큐(조명·음향) 정보로 음성인식을 켜고 끄는 구성과 관객 기기로 자막을 보내는 구성을 포함하는데, 우리 시스템은 둘 다 하지 않아 핵심 구성은 겹치지 않는다고 판단함. 구현은 공개된 일반 알고리즘(문자열 유사도, 상태 기계)으로 하고, 3단계나 콘솔 연동으로 넓힐 때 다시 확인함.

(4) 비교 분석

구분	유니스텝 (현재)	국회 생중계 자막	아울	영국 국립극장	본 프로젝트
방식	수동 송출	실시간 STT 자막	대본 동기화 + 자동 송출 지원	대본 동기화 + 자동 송출	대본 동기화 + 사람 송출
송출 판단	사람	AI 자동	AI 자동(무인 운영 가능)	소프트웨어 + 운영팀	사람 (보조 화면 참고)
음성인식 역할	없음	인식 결과가 곧 자막	대본 위치 동기화	대본 위치 추적	대본 위치 추적만
애드리브	빈 자막	해당 없음	공개 자료에서 확인 안 됨	공개 자료에서 확인 안 됨	이탈 감지·복귀 큐 표시

구분	유니스텝 (현재)	국회 생중계 자막	아울	영국 국립극장	본 프로젝트
필요 인프라	노트북	전용 음성인식 엔진·중계 시스템	전용 안경	조명·음향 큐 연동 (극장 기술팀)	노트북
공개 여부	비공개	공공기관 자체 시스템	비공개 상용	비공개	오픈소스

* 대본 동기화 기술은 이미 있으나, 사람이 송출할 때 대본 이탈과 복귀 위치를 알려 주는 도구는 공개 자료에서 확인되지 않음.

☻ 3. 요구사항 분석 :

(1) 요구사항과 기능

ID	요구사항	우선순위	구현 기능(모듈)
R1	현재 대본 위치를 보조 화면에 표시 (목표치는 정량 목표 참조)	Must	③ 음성인식, ④ 정렬, ⑥ 보조 화면
R2	대본 이탈을 감지해 유형(누락·반복·애드리브)을 구분하고, 대본 복귀 시 복귀 큐 번호 표시 (목표치는 정량 목표 참조)	Must	⑤ 이탈 감지
R3	보조 화면에 송출 버튼을 두되 AI는 추천만 하고 송출은 오퍼레이터가 확인 후 직접 함(실제 관객 송출은 송출 프로그램 연동 후). 기존 송출 프로그램은 변경하지 않음	Must	⑥ 보조 화면
R4	마이크 외 전용 장비 없이 오퍼레이터 노트북 한 대에서 동작	Must	② 오디오 입력, ③ 음성인식
R5	사회혁신가의 자막 큐 파일을 읽음 (파일 형식 확인 후 구현)	Must	① 큐 시트 로더
R6	일치 점수가 기준 미만이거나 노래 구간·음향 입력 끊김일 때는 알림을 띄우지 않음	Must	⑤ 이탈 감지
R7	처음 쓰는 오퍼레이터도 10분 안내 후 사용 (SUS 70점 이상)	Should	⑥ 보조 화면 설계
R8	추정 위치·이탈·복귀 이벤트 기록 (성공 기준 측정용)	Must	⑦ 회차 로그
R9	송출 중인 큐와 추정 위치의 차이 표시 (송출 프로그램 연동 확인 시)	Should (2단계)	⑧ 송출 큐 연동

	<table><tr><th>ID</th><th>요구사항</th><th>우선순위</th><th>구현 기능(모듈)</th></tr><tr><td>R10</td><td>오퍼레이터가 켠 구간만 다음 큐로 자동 전진 (연동과 사회혁신가 동의 시)</td><td>Could (3단계)</td><td>⑨ 자동 전진 제어</td></tr><tr><td>–</td><td>관객 자막 자동 송출, 스마트안경 등 하드웨어</td><td>Won't</td><td>범위 제외</td></tr></table> 비기능 요구: 현장 음성은 실시간 처리 후 저장하지 않음, 오픈소스 라이선스 준수. 보조 화면은 기존 송출 화면을 가리지 않아야 함(같은 노트북 분할 화면·별도 창·보조 모니터 중 현장 확인 후 결정) ▪ **중간 시점 구현 상태:** R1, R3, R4, R5, R6, R8은 구현함. R2는 애드리브 3건을 모두, 누락은 3건 중 2건을 잡지만 반복은 3건 중 1건이라 보완 중. R7(사용성)은 오퍼레이터 시험 때 잴 예정이고, R9와 R10은 송출 프로그램 연동을 확인한 뒤 시작함. 요구사항에 없던 '위치 직접 맞추기'(대본 줄 클릭)는 시험하면서 필요해서 추가함.
목표 및 내용	**☻ 개발목표 :** ▪ **최종 목표:** 공연 중 현장 음성과 사전 제작 대본을 비교해, 오퍼레이터에게 현재 대본 위치와 대본 이탈·복귀 큐 번호를 보조 화면에 표시하는 소프트웨어를 개발함. 1단계를 완성해 공개 공연 영상으로 전체 흐름을 시연하는 것을 학기 최종 목표로 함. 2·3단계는 송출 프로그램 연동과 사회혁신가 동의 여부에 따라 진행함. **정량 목표** <table><tr><th>지표</th><th>중간 측정 (10/25)</th><th>목표</th><th>측정 방법</th></tr><tr><td>위치 추적 정확도</td><td>90.7% (공연 녹음, 실시간) / 녹음 3개 평균 87.2%</td><td>90% 이상 (±1큐)</td><td>공연 녹음 3.5분 + 사람이 찍은 정답 라벨</td></tr><tr><td>화면 표시 지연</td><td>대사 시작 → 화면 표시 중앙 2.5초</td><td>2초 이내</td><td>로그 타임스탬프</td></tr><tr><td>대본 복귀 → 복귀 큐 표시</td><td>합성 이탈 녹음에서 중앙 3.0초, 최대 5.7초 (현장 기준선은 아직)</td><td>5초 이내</td><td>애드리브를 넣은 모의 음원</td></tr><tr><td>사용성</td><td>아직 (오퍼레이터 시험 때)</td><td>SUS 70점 이상, 10분 안내</td><td>처음 쓰는 오퍼레이터·팀 외부 사용자 설문 (SUS 평균 약 68점 [15], 설문 원형[25])</td></tr><tr><td>자동 전진 오송출 (3단계, 동의 시)</td><td>해당 없음 (3단계 시작 전)</td><td>0건</td><td>모의 공연 전체</td></tr></table> ※ 수치는 팀이 제안하는 초안이며, 10월 공연 참관은 하지 못해 기준선은 11/13 현장 체험(공연 참관) 때 처음 재고, 그 뒤 사회혁신가와 확정함. 화면 표시 지연(2초)은 위치 표시가 판단에 쓸 수 있을 만큼 제때 나오는지 보는 기준이며, 핵심 성과는 대본 이탈 뒤 복귀 시간(현장 최대 30초 → 목표 5초) 단축임. * 중간 측정은 10/25에 실시간으로 잰 값(공연 녹음 3.5분 1개, 이탈을 넣은 합성 녹음 2개). 실제 공연장에서 잰 값이 아님.

단계별 목표



[그림 1] 3단계 로드맵과 오퍼레이터 역할의 변화

- **창의성과 난이도:** 음성인식 결과를 미리 검수된 대본과 맞춰 공연 진행 위치를 추적하는 구조임. 음악과 소음이 섞인 공연 음성의 한국어 인식, 표현이 조금씩 다른 대사를 맞추는 유사도 비교, 누락·반복·애드리브를 가르는 상태 기계가 핵심 난제임.

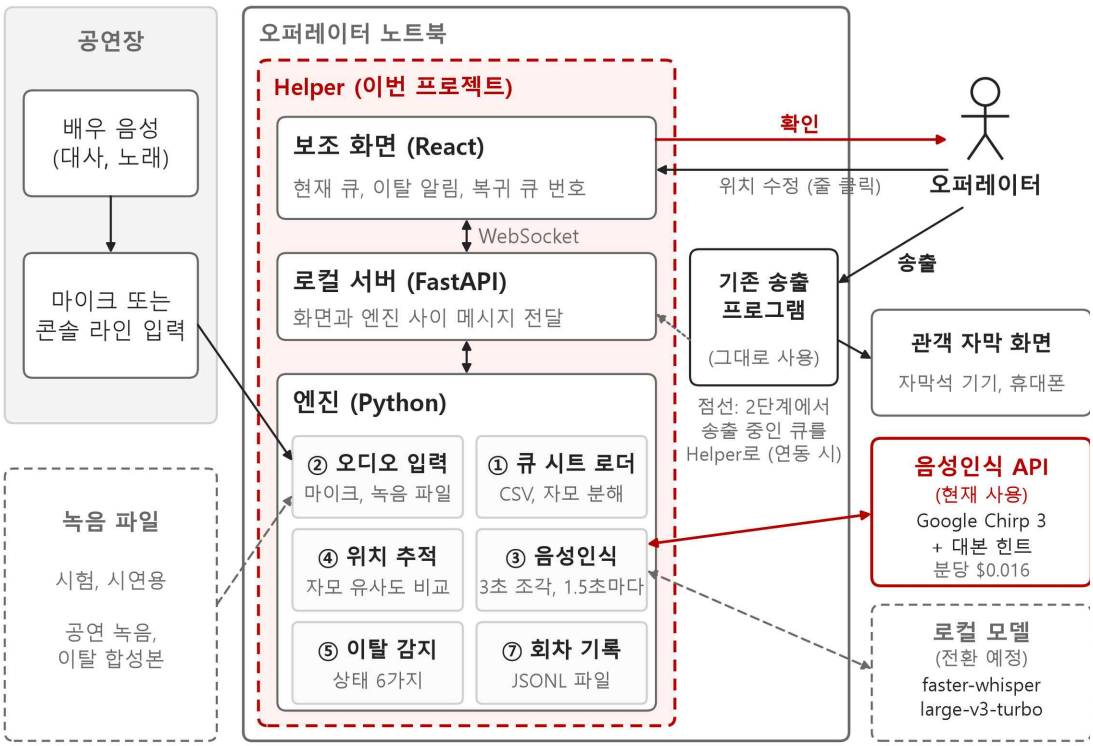
☻ 개발내용 :

(1) 최종 결과물의 형태

- 오퍼레이터 노트북에서 실행되는 설치형 소프트웨어: 파이썬 추적 엔진 + 웹 브라우저 기반 보조 화면. 기존 송출 프로그램과 별도로 실행하며, 하드웨어 제작 없음.
- 음성인식: 같은 녹음으로 비교해 정하기로 했고, 10/12 비교에서 Chirp 3 + 대본 힌트가 79%로 가장 정확해(CLOVA 49%, ETRI 44%, whisper small 37%) API로 먼저 만들었음. 음성인식 부분만 바꿔 끼울 수 있게 만들어서 로컬 모델로 바꿔도 ④ 대본 정렬 엔진 이후 코드는 그대로 씀.

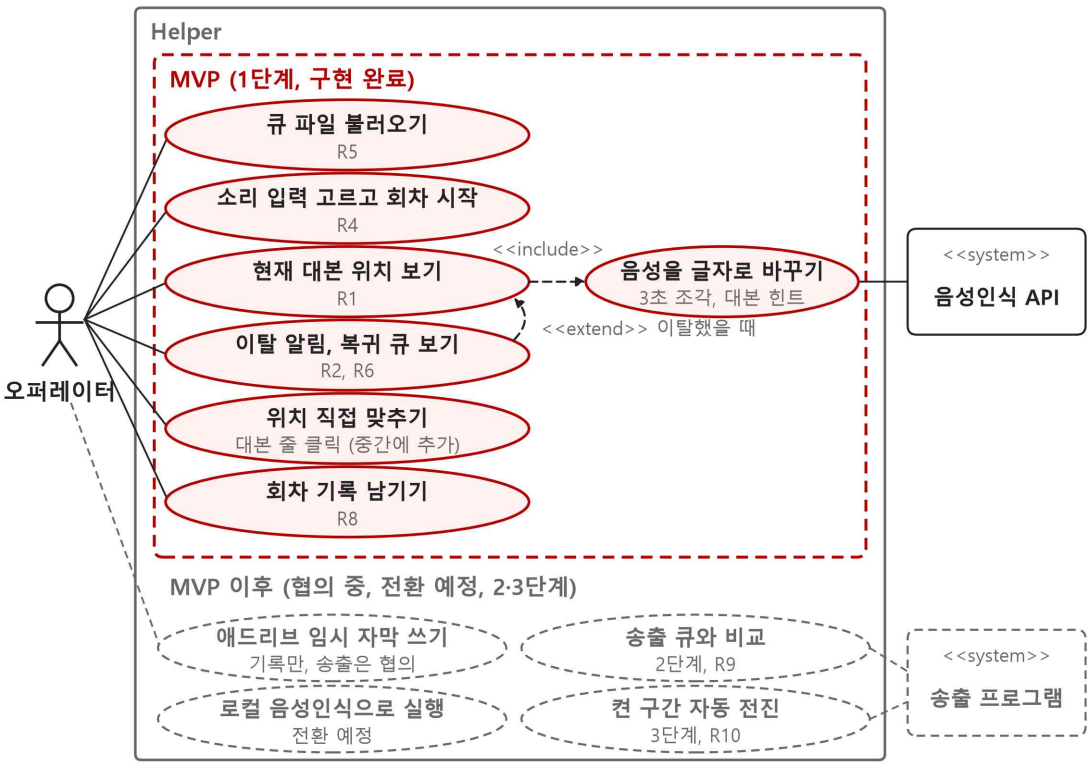
(2) 전체 시스템 설계

- **구현된 구조(그림 2):** 엔진(Python), 로컬 서버(FastAPI), 보조 화면(React)이 모두 오퍼레이터 노트북 안에서 돌고, 밖으로 나가는 것은 음성인식 요청뿐임. 엔진은 소리 받기, 음성인식, 화면 전송을 따로 돌려서 인식이 늦어져도 소리를 놓치지 않음. 제안 때 구성도는 붙임 1.



[그림 2] 구현된 시스템 아키텍처 (사용자, 클라이언트, 서버, 엔진, 외부 서비스)

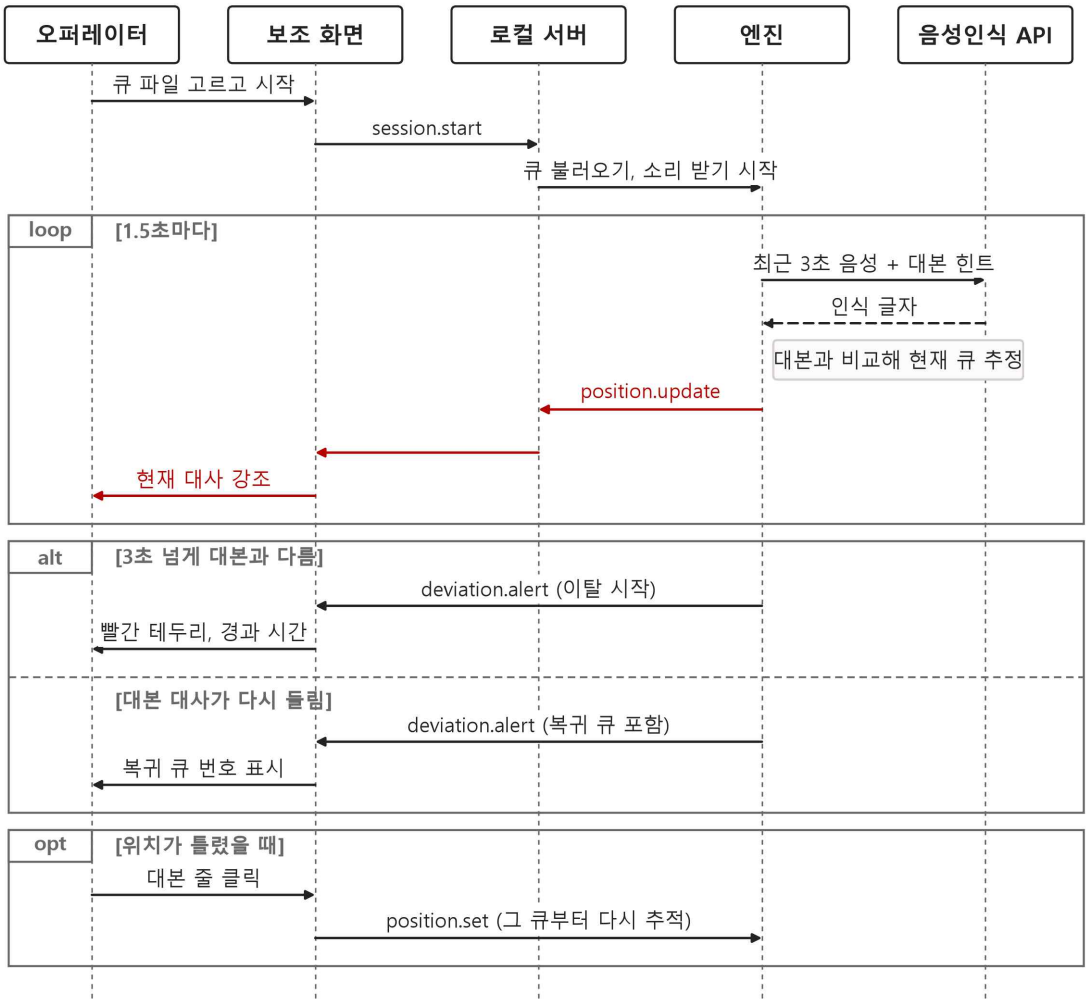
- **유스케이스와 MVP 범위(그림 3):** 1단계 Must 기능을 MVP로 묶어 먼저 만들었음. 큐 파일 불러오기, 회차 시작, 현재 위치 보기, 이탈·복귀 보기 순서로 만들었고, 시험 중에 위치를 바로잡는 기능이 필요해서 더함. 임시 자막, 로컬 음성인식, 2·3단계 기능은 MVP에 넣지 않음.



[그림 3] 유스케이스 다이어그램 (빨간 점선 안이 MVP)

- **시연 흐름(그림 4):** 회차를 시작하면 엔진이 1.5초마다 최근 3초 소리를 대본 힌트와 함께

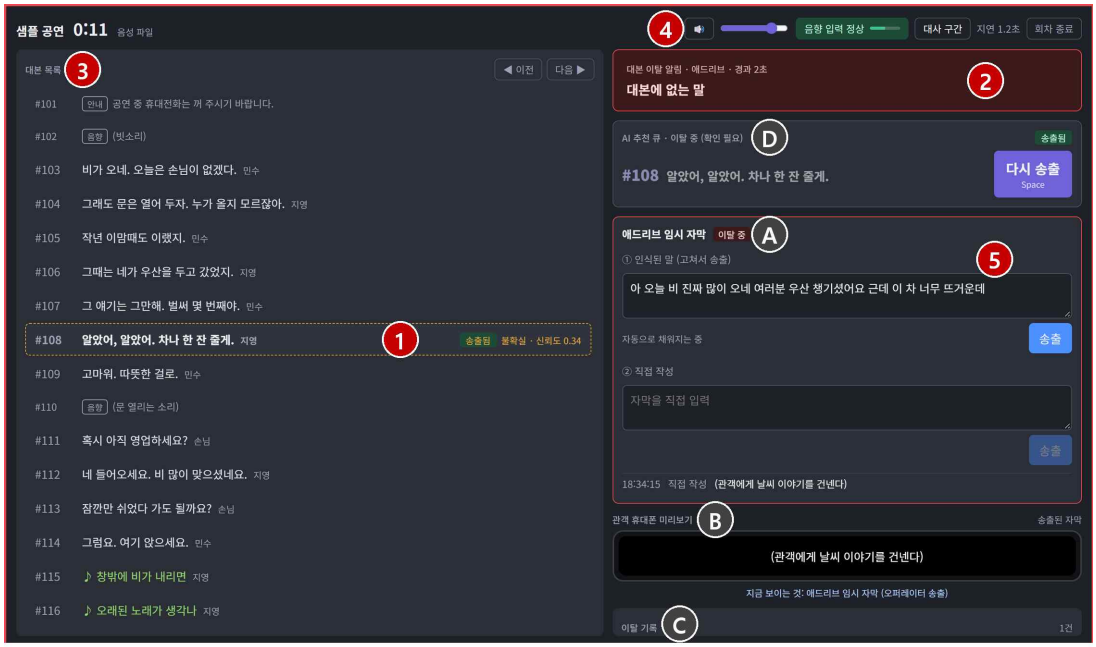
음성인식에 보냄. 돌아온 글자를 대본과 비교해 현재 큐를 화면에 보냄. 3초 넘게 대본과 맞지 않으면 이탈 알림을, 대본 대사가 다시 들리면 복귀 큐 번호를 띄움. 제안 때 그린 처리 흐름과 실제 이탈 감지 상태는 붙임 2·3.



[그림 4] 시연 과정 시퀀스 다이어그램

(3) 화면 설계 (화면 구조 포함)

- **실제 구현 화면(그림 5):** 와이어프레임(붙임 5)처럼 왼쪽에는 대본 목록과 현재 큐, 오른쪽에는 이탈 알림을 둠. 번호 ①~⑤는 와이어프레임의 화면 요소 번호와 같음. AI 추천 큐 송출 칸(R3)을 두고, 시험용으로 애드리브 임시 자막 칸, 관객 휴대폰 미리보기, 이탈 기록을 더했음. 이탈 중에는 화면 테두리가 빨갛게 바뀜. 시작 화면과 복귀 장면은 붙임 7.



1 현재 위치와 신뢰도 (#108, 불확실 0.34)
2 이탈 알림 (애드리브, 경과 2초)
3 대본 목록 (줄을 누르면 위치 맞추기)
4 입력 상태 (음향 입력, 대사 구간, 지연)
5 인식 글자 (이탈 중 들린 말)
A 애드리브 임시 자막 (확인 후 송출)
B 관객 휴대폰 미리보기 (송출한 자막)
C 이탈 기록 (이번 회차)
D AI 추천 큐와 송출 버튼 (Space)

[그림 5] 실제 보조 화면 (녹음 재생 중 애드리브로 이탈한 장면)

(4) 데이터와 인터페이스

- **실제 구현(그림 6):** 큐 파일은 CSV로 받고, 엔진의 현재 상태는 메모리에만 둠. 회차 기록은 SQLite 대신 JSONL 파일로 남김. 회차마다 파일 하나가 생기고, 그 파일을 평가 도구에 그대로 넣어 다시 채점할 수 있어서 바꿨음. 화면과 엔진 사이 메시지는 계획한 7종(2단계 송출 큐 포함)에 5종(위치 맞추기, 대사 입력 테스트, 임시 자막 기록, 대본 큐 송출, 엔진 오류)을 더해 12종이고, HTTP는 상태 확인과 녹음 파일 2개.

Cue	큐 파일 CSV
id	큐 번호 (PK)
order	대본 순서
type	대사, 가사, 음향 등
speaker	화자
text	한국어 대사
act, scene	막, 장 (선택)

TrackerState	엔진 메모리
cue_id	현재 추정 큐 (FK)
confidence	일치 점수 0~1
state	정상, 이탈 등 6가지
since	이탈 시작 시각
return_cue_id	복귀 큐 번호

SessionLog	회차 기록 JSONL
kind	start, stt, step 등
wall	기록 시각 (ms)
stt	인식 글자, 처리 시간
step	추적 판단 (큐, 점수)
alert	이탈 유형, 복귀 큐

화면 ↔ 엔진 통신: WebSocket 메시지 12종(계획 7 + 만들면서 추가 5)과 HTTP 2개

방향	메시지		주요 필드
화면 → 엔진	**session.start**		show_id, cue_file, input (회차 시작)
	session.end		show_id (회차 끝)
	settings.update		alert_threshold (알림 기준)
	position.set	추가	cue_id (대본 줄을 눌러 위치 맞추기)
	test.say	추가	직접 넣은 대사 (마이크 없이 시험)
	subtitle.send	추가	애드리브 임시 자막 (오퍼레이터가 확인 후 송출)
	cue.send	추가	cue_id, grouped_ids (AI 추천 큐 송출)
엔진 → 화면	**position.update**		cue_id, confidence, latency_ms, transcript
	deviation.alert		deviation_type, since, return_cue_id
	input.status		audio_level, segment, audio_sec
	engine.error	추가	message, during (음성인식 오류 등)
송출 → 엔진	**cue.onair**	2단계	cue_id, sent_at (연동될 때)
HTTP	**GET /health**		엔진 상태 확인 (어느 음성인식을 쓰는지)
	GET /session/audio		재생 중인 녹음 파일 (화면에서 같이 듣기)

[그림 6] 데이터 스키마와 화면 · 엔진 통신 (WebSocket, HTTP)

☻ 대안 도출 및 구현 계획

- **대안 비교:** 완전 자동 음성인식 자막(오인식이 관객에게 그대로 보이고 사회혁신가가 시도 후 중단), 대본 동기화 + 전 구간 자동 송출(아울 방식, 동기화가 틀리면 오송출), 타임코드 자동 재생(애드리브 대응 불가), 조명·음향 콘솔 큐 연동(극장마다 방식이 다름)을 비교해, 관객 자막은 검수된 자막 그대로 두고 음성인식은 위치 표시에만 쓰는 방식을 골랐음(녹음으로 잰 위치 정확도 90.7%). 자동 송출은 오퍼레이터가 켠 구간에서만 3단계로 검토하고, 콘솔 연동은 3단계 이후 과제로 둠.

단계별 구현 방법

- **1단계:** 음성인식은 같은 음원으로 비교해 Google Chirp 3로 정했고, 무음 감지(silero-vad)는 노래 위 대사를 버려서 기본으로는 끄고 3초 조각을 1.5초 간격으로 겹쳐 인식함. 대본과 인식 결과를 정규화(기호·공백 제거, 자모 분해. 숫자 읽기 통일은 아직)한 뒤 문자열 유사도로 비교. 탐색 구간은 [현재-3, 현재+10] 큐(초기값, 실험으로 조정). 임계값 미만이 일정 시간(3초로 정함) 지속되면 전체 범위를 재탐색해 현재보다 뒤 큐에서 발견되면 누락, 앞 큐에서 발견되면 반복, 대본 어디에서도 발견되지 않으면 애드리브로 분류하고 다시 일치하는 큐가 나오면 복귀 큐로 표시.
- **2단계(연동 확인 시):** 송출 프로그램에서 현재 송출 큐 번호를 받을 수 있으면, 추정

위치와의 차이(예: 2줄 차이)를 보조 화면에 표시. 연동 방식은 사회혁신가에게 확인 중.

- **3단계(연동과 사회혁신가 동의 시):** 오퍼레이터가 켠 구간에서만, 신뢰도·연속 일치가 기준(초기값: 신뢰도 0.9, 연속 2회) 이상일 때 다음 큐로 전진하고 그 외에는 오퍼레이터가 송출. 이상 징후 시 자동 전진을 끔.

구현하면서 생긴 문제와 해결 (유스케이스 기준)

- **현재 위치 보기:** 3초 조각을 하나씩 보내면 경계에서 단어가 잘려 54%였음. 대본 힌트를 붙이고 1.5초씩 겹쳐 보내 83%로 올림(대신 요금 2배).
- **현재 위치 보기(실시간):** 실시간으로 돌리니 응답이 밀려 조각을 건너뛰었음(77%). 요청을 3개씩 동시에 보내고(86.6%) 추적기를 다듬어 90.7%가 됨.
- **이탈 알림:** 애드리브가 멀리 있는 대사와 비슷하면 그쪽으로 넘어갔음(37%). 먼 이동은 근처 대본이 이어 들릴 때만 허용해 2%로 줄임. 줄 끝을 말하면 다음 줄로 미리 넘어가던 문제도 고침.
- **회차 시작:** 무음 감지(VAD)가 음악 위 대사와 노래를 버려 정확도가 83%에서 55%로 떨어져서 기본으로 끔.
- **음성인식 API:** 시험을 여러 개 동시에 돌리다 Google 요청 한도(429 오류)에 걸려 동시 요청 수를 줄이고, 오류가 이어지면 화면에 알림을 띄움.
- **로컬 모델(10/29):** 같은 녹음 · 같은 채점으로 비교하면 large-v3-turbo는 처리 지연이 없다고 볼 때 89.0%로 Chirp 3(92.9%)에 가깝지만, 노트북 CPU로는 3초 조각 하나에 7초쯤 걸려 실시간으로는 25.9%[20][21]. small은 내장 무음 거르기를 끄면 29.8%에서 56.8%로 오름. GPU 장비를 알아보는 중.

MVP 구현 방식

- **바이브코딩과 검증:** 코드는 Claude Code로 만들었음. 만든 코드는 팀이 읽어 보고 실제 녹음으로 돌려 숫자를 확인한 다음 PR로 합침. 지금까지 PR 19건, 자동 테스트 101개이고, PR을 올릴 때마다 GitHub Actions가 테스트와 화면 빌드를 확인함.

☻ 설계의 현실적 제한요소(제약조건)

구분	제약과 대응
비용	Chirp 3는 분당 $0.016[19]. 조각을 겹쳐 보내서 공연 1회(150분)에 약 6,700원이 듦. 개발 중에는 약 900분(약 1.9만 원)을 Google 무료 크레딧으로 씀. 사회혁신가는 추가 비용이 생기는 API보다 로컬을 원해서 같이 검토 중. 추가 장비는 마이크 정도
동작 환경	오퍼레이터 노트북 한 대(사양 확인 중), 공연장마다 다른 오디오 입력 조건. 지금 API 방식은 인터넷이 필요하고, 로컬 모델은 GPU가 없으면 실시간 처리가 안 됨
개발 환경	3인 팀 전원이 개발에 참여하며 모듈별 주 담당을 둠. 실질 개발 기간 약 10주이므로 1단계를 필수로 두고, 2·3단계는 연동·동의 여부에 따라 진행

구분	제약과 대응
법·저작권	대본과 공연 음원은 제작사 자산이므로 저장소에 포함하지 않음. 공연 영상은 제공받을 수 없어(저작권, 사회혁신가 답변) 개발·검증에는 공개 희곡, 자체 녹음, 유튜브 공개 공연 영상 재생음을 사용
개인정보	객석 음성은 저장하지 않음. 회차 기록에는 인식 글자와 추정 큐가 남아 대본이 들어가므로 저장소에 올리지 않음. API를 쓰면 음성이 외부 서버로 가므로 현장 사용 전 동의 필요
안전	보조 프로그램은 기존 송출 프로그램과 분리되어, 보조 프로그램이 멈춰도 자막 송출은 그대로 유지됨
윤리	송출 판단과 실행은 오퍼레이터가 함

☻ 개발 환경 (구현 계획)

(1) 시스템 구성

- **서버:** 별도 서버 없이 오퍼레이터 노트북 안에서 로컬 서버(FastAPI)가 음성 처리·정렬 엔진을 실행하고, 보조 화면(React)과 WebSocket으로 실시간 통신함. 회차 기록은 JSONL 파일로 저장(계획의 SQLite에서 바꿈).
- **외부 통신:** 지금은 음성인식 API(Google Chirp 3, us 지역)를 쓰므로 인터넷이 필요함. 키 파일은 저장소 밖에 두고 .env로만 읽음. 송출 프로그램 연동(2단계)과 오롯플래닛 시스템 결합은 방식을 확인한 뒤 설계함. 구조는 그림 2.

(2) 권장 하드웨어

- **노트북과 입력:** 4코어 이상 CPU, RAM 16GB, Windows 11 또는 macOS 노트북이면 API 방식은 충분함. 로컬 모델(large-v3-turbo)을 실시간으로 쓰려면 GPU가 필요함. 소리는 USB 마이크나 오디오 인터페이스(콘솔 라인 입력)로 받음. 현장 노트북 사양은 사회혁신가에게 확인 중.

(3) 기술 스택

영역	기술	선택 이유
음성 처리	Python 3.11, sounddevice, silero-vad(선택) / 음성인식: Google Speech-to-Text Chirp 3 (선택), faster-whisper (로컬 병행 시험)	같은 녹음으로 비교해(10/12) 정확도가 가장 높은 Chirp 3 선택, 로컬은 사회혁신가 요청으로 병행
정렬·이탈 감지	rapidfuzz 부분 일치, jamo 자모 분해, 상태 기계(정상·의심·재탐색·이탈·노래·입력 없음)	표현이 조금 달라도("반갑습니다"·"반가워요") 자모 단위로 맞춰 봄
로컬 서버	FastAPI, WebSocket	인식 결과를 보조 화면에 즉시 전달

영역	기술	선택 이유
보조 화면	React + Vite (TypeScript)	위치·알림이 수시로 갱신되는 화면 구현
데이터	JSONL 파일 (회차 기록)	회차마다 파일 하나, 평가 도구로 다시 채점 가능 (SQLite 대신)
테스트·배포	pytest, GitHub Actions, GitHub Releases	자동 테스트, 설치 파일 배포
패키징	PyInstaller (FastAPI가 React 빌드 파일을 함께 제공, 실행 시 브라우저로 접속)	설치 파일 하나로 실행. GitHub Releases로 배포

(4) 저장소와 협업

- GitHub 저장소: ./Src(엔진·서버·화면 소스), ./Doc(수행계획서·발표자료·회의록·보고서), README.md.
- 협업 도구: GitHub(이슈·PR), Notion, Slack, Figma. 라이선스는 의존 라이브러리 검토 후 MIT 또는 Apache-2.0 중 선택(14주차 확정).

(5) 단계별 검증 계획

- **단계와 진행 상태(11/3):** ① 기술 검증(표현 차이 통과, 음성인식 비교, 지연 측정)은 마침. ② 기준선 측정(현장에서 지금 송출 방식 관찰)은 10월 공연 참관을 못 해 11/13 현장 체험(공연 참관) 때 함. ③ 모의 공연(위치 정확도 90%, 복귀 큐 표시 5초)은 공연 녹음과 이탈을 넣은 녹음으로 대신해 90.7%, 3.0초로 넘었고, 표시 지연 2.5초는 아직 목표 2초 미달. ④ 오퍼레이터 시범(10분 안내 후 SUS 70점)은 11월 말 예정.

기대효과

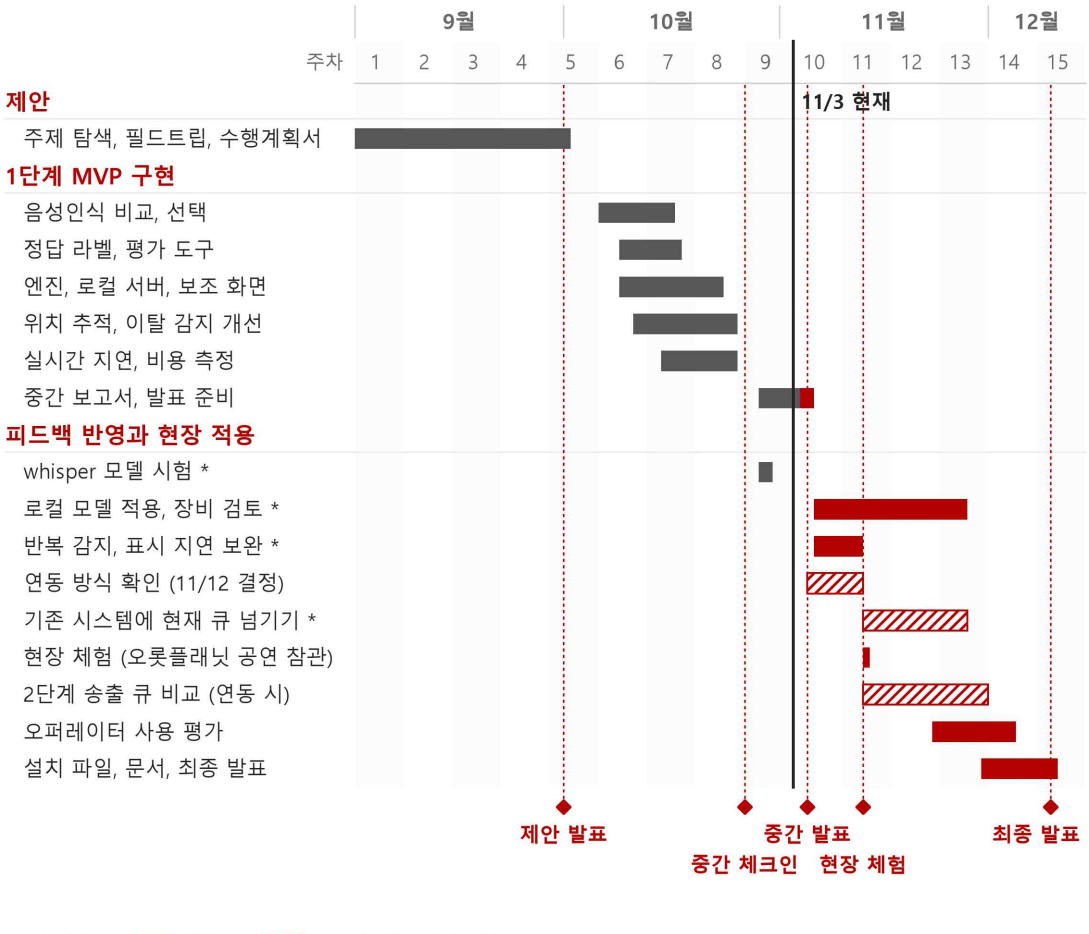
☻ 이 시스템이 개발되면 누구에게 어떤 도움을 줄 수 있는가?

- **오퍼레이터:** 애드리브·대사 누락 뒤 배우가 돌아온 큐 번호를 보조 화면에서 확인할 수 있어, 기억에 의존하던 위치 찾기를 도구가 보조함. 외부·외국인 오퍼레이터도 같은 화면으로 위치를 확인할 수 있음.
- **사회혁신가(오롯플래닛):** 회차 로그로 애드리브·대본 이탈이 언제, 몇 번 생기는지 처음으로 기록됨. 오퍼레이터 부담 변화는 SUS 설문과 로그로 확인함.
- **관객(외국인·청각장애인):** 대본 이탈 뒤 올바른 자막이 다시 송출되기까지의 시간 단축을 목표로 하며, 모의 공연에서 복귀 큐 표시 시간으로 측정함.
- **사회적 측면:** 공연 자막 송출 보조 도구를 오픈소스로 공개해 다른 자막 운영 단체도 활용할 수 있음.
- **확장성:** 대본 위치를 실시간으로 아는 엔진은 사회혁신가가 우선순위가 높다고 언급한 음성 화면 해설[1], 조명·음향 콘솔 연동으로 확장할 수 있음.

추진일정

☻ 세부 작업에 대한 간트차트

- **중간 시점(11/3) 수정 일정:** 1단계 MVP는 계획대로 중간 발표 전에 완성함(그림 7). 사회혁신가 요청으로 로컬 모델 전환과 오롯플래닛 기존 시스템과의 결합을 일정에 새로 넣었음. 결합은 10/27 의견대로 엔진이 찾은 현재 큐 번호를 오롯플래닛 시스템에 넘기는 방식이고, 11/12까지 자막 번호 체계와 전달 방식을 확인한 뒤 11월 말까지 연결부를 만듦. 2단계(송출 큐 비교)도 같은 날 진행 여부를 정함. 11/13에는 오롯플래닛 공연 현장 체험(참관)으로 오퍼레이터의 실제 송출과 공연장 환경을 보고, 우리 시스템을 현장에서 써 보는 것은 따로 협의함. 최종 발표에서는 녹음으로 확인한 것과 현장에서 해 본 것을 나눠서 보여 줄 예정. 제안 때 일정은 붙임 8·9.



* 제안 이후 새로 넣은 일. 3단계(켠 구간 자동 전진)는 2단계 연동이 되고 사회혁신가가 동의하면 진행 여부를 정함

[그림 7] 추진 일정 (11/3 기준, 제안 이후 바뀐 일정 반영)

☻ 세부 작업 별 구성원의 역할

구성원	역할 (개발은 전원 참여, 모듈별 주 담당)
김소영 (팀장·기획)	사회혁신가·멘토 소통과 일정 관리, 요구사항·KPI(성공 기준) 설계, 발표 총괄 (제안 단계: 주제 탐색·필드트립·문제 정의 주도) / 개발: ① 큐 시트 로더, 테스트 데이터 제작 (큐·정답 라벨), ⑦ 회차 로그, 위치 추적 정확도 측정

구성원	역할 (개발은 전원 참여, 모듈별 주 담당)
강지호 (개발)	②③ 오디오 입력·음성인식, ④ 대본 정렬 엔진, ⑤ 이탈 감지, 로컬 서버 (FastAPI·WebSocket)와 모듈 통합, ⑧ 송출 큐 연동(2단계)·⑨ 자동 전진 판단(3단계), 기술 스택 검증, 테스트 자동화와 저장소 관리, 표시 지연·복귀 시간 측정, 수행계획서·보고서 초안 정리
이동은 (디자인)	⑥ 보조 화면·준비 화면·설정 화면 UX/UI와 프론트엔드, ⑧·⑨ 화면 표시와 켜고 끄기, 공연장 환경에 맞춘 알림 표시와 화면 배치 설계, 오퍼레이터 사용 안내 자료, SUS 사용성 평가, 발표 자료 디자인
공통	주 1회 정기 회의, 코드 리뷰와 통합 테스트, 공연 참관과 현장 시험, 단계 종료 시 점검 회의

중간 발표까지 한 일

- **김소영:** 회의 진행과 기록, 사회혁신가 문의 사항 정리와 소통(데이터 출처, 큐 파일 구조, 현장 일정), 중간 체크인 발표 구성과 자료 취합, 질의응답과 교수님 피드백 정리, 11/13 현장 체험 준비.
- **강지호:** 엔진과 로컬 서버 개발, 음성인식 비교와 Chirp 3 선택, 위치 추적과 이탈 감지 개선, 성능과 비용 측정, 로컬 모델 시험, 시연 영상.
- **이동은:** 보조 화면과 모의 서버 개발, 대사 입력 테스트 · 휴대폰 자막 미리보기 · 애드리브 임시 자막 등 화면 기능 추가, 화면 배치 정리, 발표 자료 디자인.

☻ 위험 요소와 대응

- **위험과 대응:** 음악 · 소음 속 인식 저하는 콘솔 라인 입력과 노래 구간 알림 보류로, 송출 프로그램 연동이 안 되면 보조 화면 단독(1단계)과 정확도 개선으로, 3단계 자동 전진의 오송출은 보수적인 기준과 모의 공연 오송출 0건 확인으로 대응함. 실제 공연 음원 대신 공연 녹음 · 이탈 합성 녹음 · 유튜브 공개 영상으로 개발하고, 현장에서 써 볼 기회가 없으면 공연 영상 모의 시험과 오퍼레이터 인터뷰로 대신함. 노트북 성능이 모자라면 API 방식을 유지하고 로컬은 small 모델이나 GPU 장비로 함.

	항목	세부내용	예상(달성)시기
성과 창출 계획	Github	CSID-DGU/2026-2-OSSProj-Helper-03 저장소에 소스코드(엔진·서버·보조 화면, PR 19건, 자동 테스트 101개)와 문서(수행계획서·중간보고서·회의록)를 공개 중. 라이선스는 14주차에 정함	생성 2026.9 / 중간 2026.11 / 최종 2026.12
	논문게재 및 참가	저널 또는 학회명: 미정 (성과 발표 이후 결과에 따라 학부생 논문 투고 검토)	미정
	SW등록	한국저작권위원회 컴퓨터프로그램 저작권 등록 검토	2026.12 이후
	특허출원	계획 없음 (오픈소스 공개 우선). 선행 특허 US 10,726,842 B2 청구항 비교함(추진 배경 참고)	해당 없음

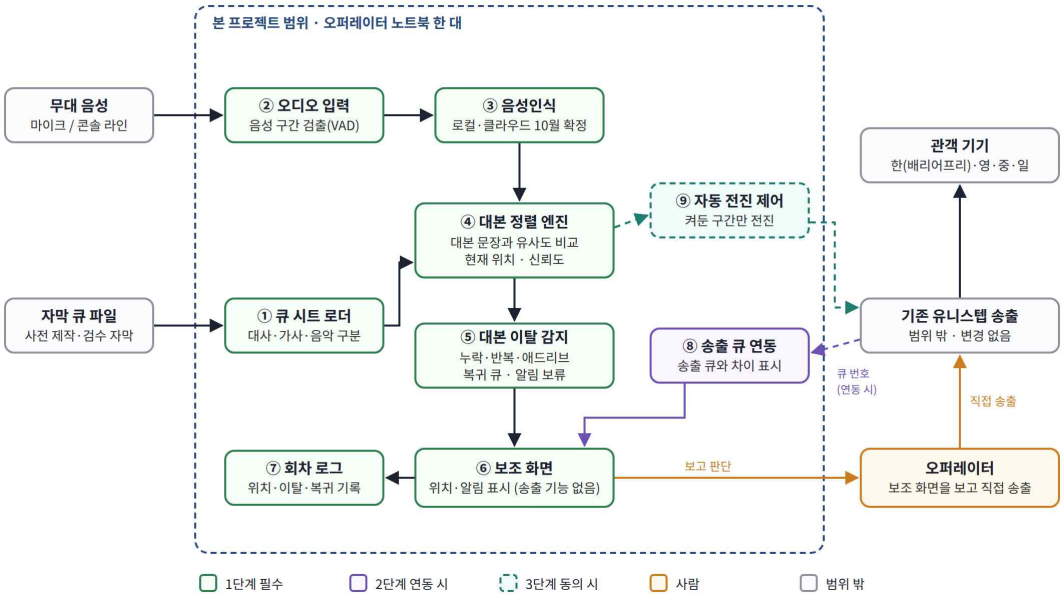
	시제품	설치형 MVP를 GitHub Releases로 배포하고 사회혁신가 현장에서 시험 (일정 협의)	2026.12

붙임

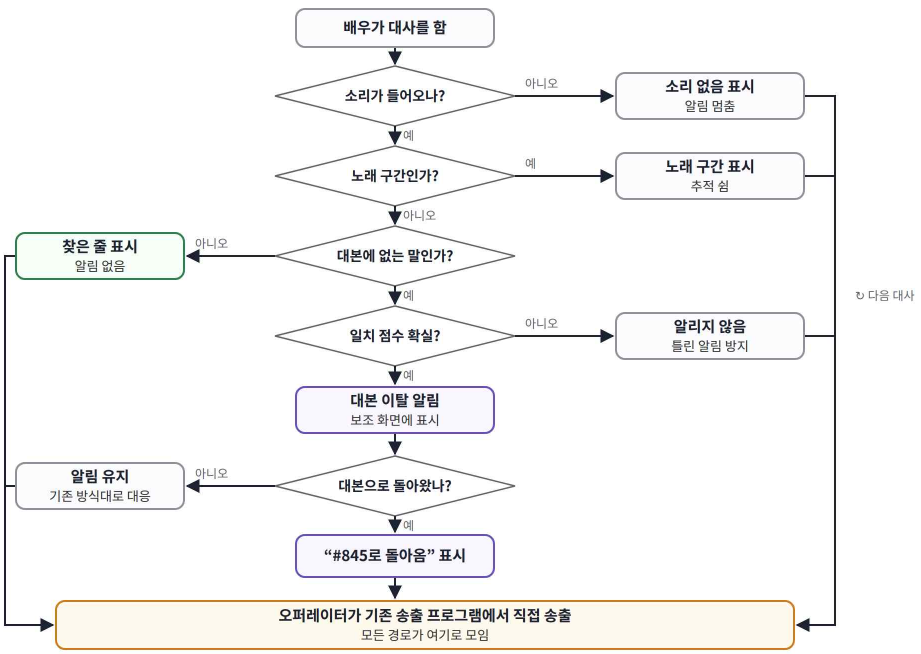
☻ 본문에 넣지 않은 그림

본문에는 주제마다 대표 그림 하나만 두고, 제안 때 그린 설계 그림과 실제 화면 캡처를 여기에 모았음. 제안 때 상세 표(사업 구조, 사용자 니즈, 설계 반영, 모듈, 메시지 · 데이터, 대안 비교, 권장 하드웨어)와 서버 구성 · 검증 절차 그림은 수행계획서(Doc/1_1)에 그대로 있음.

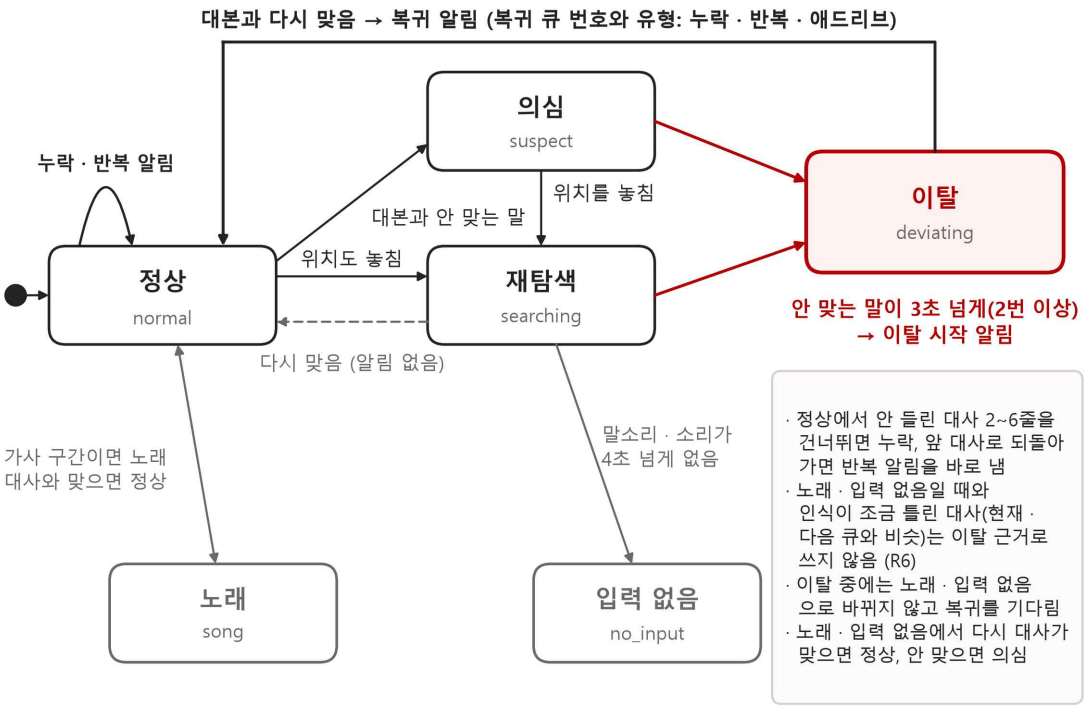
(1) 시스템 구성과 동작



[붙임 1] 제안 때 시스템 구성도 (점선 안이 본 프로젝트 범위, 색은 개발 단계)

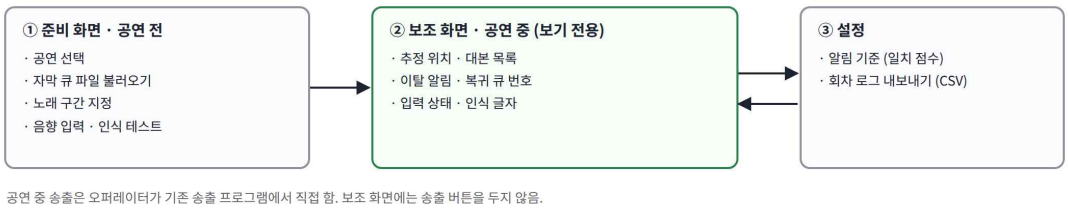


[붙임 2] 제안 때 그린 대본 추적과 이탈 처리 흐름

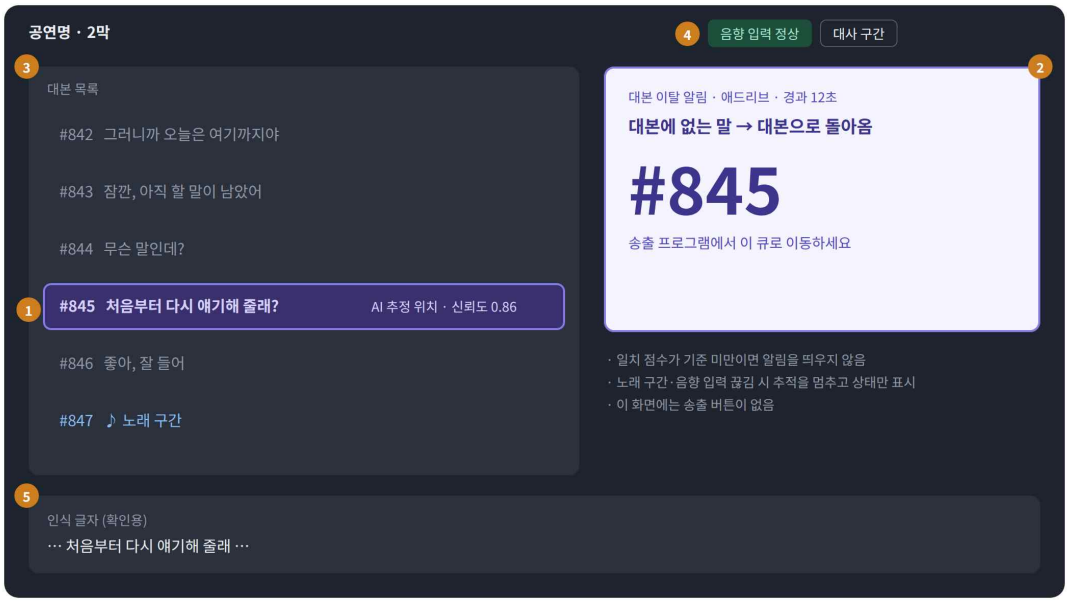


[붙임 3] 실제 이탈 감지 상태 (엔진 코드 기준 상태 6개와 바뀌는 조건)

(2) 화면 (제안 때 설계와 실제 화면)



[붙임 4] 제안 때 화면 구성과 흐름



[붙임 5] 제안 때 보조 화면 와이어프레임

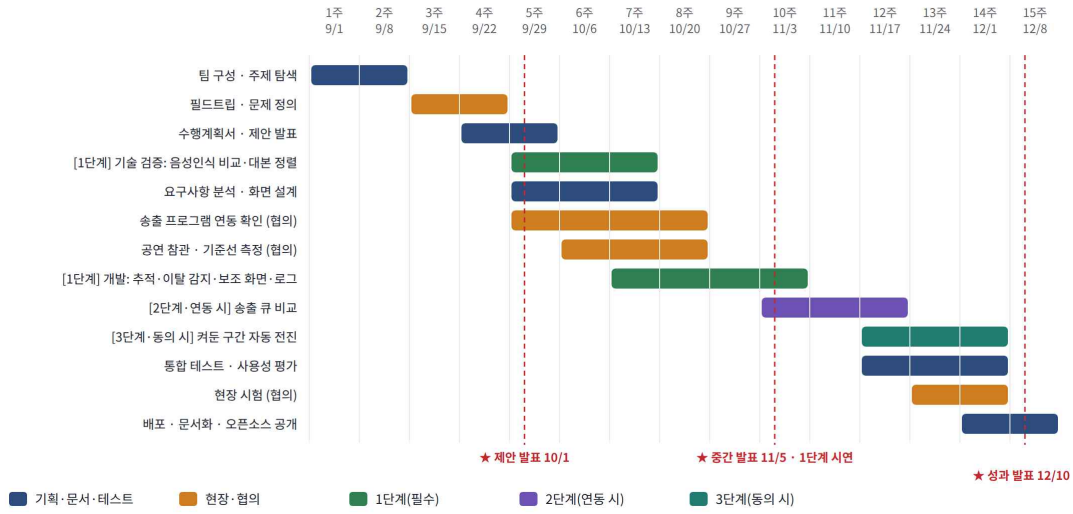


[붙임 6] 제안 때 준비 화면 와이어프레임



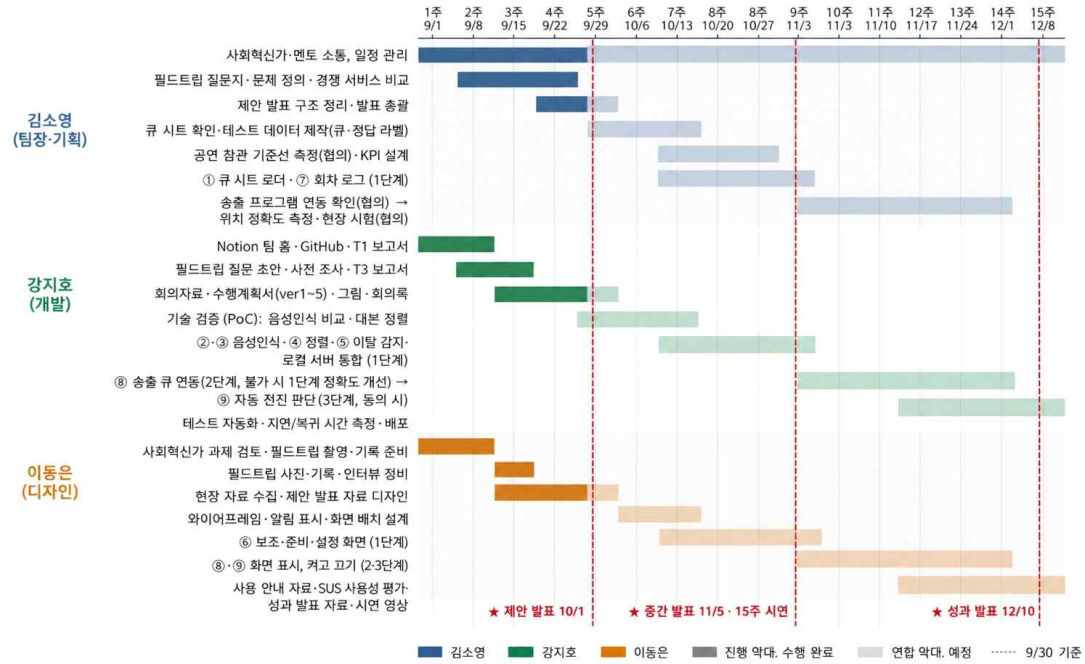
[붙임 7] 실제 화면: 시작 화면(왼쪽, 계획한 준비 화면 대신 쓰는 간단한 패널)과 대본으로 돌아온 장면 (오른쪽, 복귀 큐 #109)

(3) 일정 (제안 때)



[붙임 8] 제안 때 세운 15주 추진 일정 (★ 마일스톤, '협의'는 사회혁신가와 조율이 필요한 항목)

☻ 세부 작업에 대한 간트차트



[붙임 9] 제안 때 세운 구성원별 15주 일정

[참고문헌]

[1] 오롯플래닛 필드트립 인터뷰 기록(2026.9.15), 황운주 팀장 서면 답변(2026.9)

[2] 오롯플래닛, '공연장을 바꾸는 한 줄의 자막: 유니스텝 1년의 기록'(2025.8.8), https://www.orotplanet.com/unistep_history

[3] 더뮤지컬, '오롯플래닛 최인혜 대표, 누구나 동등한 관객이 될 수 있도록'(2025.4.18), https://www.themusical.co.kr/Magazine/Detail?num=5437

[4] 한국장애인신문, '스마트안경 아울, 청각장애인을 위한 국립극단 공연 자막 지원'(2024.1.19), http://www.koreadisablednews.com/news/articleView.html?idxno=13274

[5] 경향신문, '샤롯데씨어터, 자막 안경 출시'(2025.11.12), https://www.khan.co.kr/article/202511121353011

[6] 시선뉴스, '세종문화회관, AR 자막안경 아울 도입'(2026.6.26), http://www.sisunnews.co.kr/news/articleView.html?idxno=241375

[7] Blooloop, 'Accessibility at the National Theatre: smart caption glasses', https://blooloop.com/technology/in-depth/smart-caption-glasses-epson-national-theatre/

[8] Royal National Theatre, US 10,726,842 B2 'Caption delivery system', https://patents.google.com/patent/US10726842B2/en

[9] 이데일리, '국회 회의 실시간 자막으로…세계 최초 AI 음성인식 기술 선봬'(2023.2.22), https://edaily.co.kr/News/Read?mediaCodeNo=257&newsId=01741686635513144

[10] A. Radford et al., 'Robust Speech Recognition via Large-Scale Weak Supervision', arXiv:2212.04356, 2022

[11] R. Dannenberg, 'An On-Line Algorithm for Real-Time Accompaniment', ICMC 1984 / S. Dixon, 'Live Tracking of Musical Performances Using On-Line Time Warping', DAFx 2005

[12] K. Kuhn, V. Kersken, G. Zimmermann, 'Communication Access Real-Time Translation Through Collaborative Correction of Automatic Speech Recognition', arXiv:2503.15120, 2025

[13] 테크포임팩트 캠퍼스 2026-2학기 사회혁신가 소개(오롯플래닛), https://kakao-impact-foundation.github.io/campus_2026_spring/2026-fall/12/

[14] ㈜오롯플래닛, 테크포임팩트 캠퍼스 2026-2학기 사회혁신가 발표자료(eclass 학습자료실), 2026.9

[15] J. Sauro, 'A Practical Guide to the System Usability Scale', Measuring Usability LLC, 2011

[16] 중앙일보, '넷플릭스도 아닌데 대사가 눈앞에…공연장 등장한 AI 자막 안경 [비크닉]'(2026.3.11), https://v.daum.net/v/20260311080205112

[17] 엑스퍼트아이엔씨, '[아울] 뮤지컬 한복입은 남자 AI 공연 자막 안경 아울 도입'(2025.11), https://xpertinc.co.kr/notice/?bmode=view&idx=168804433

[18] 전자신문, '엑스퍼트아이엔씨-서울연극협회, 외국인과 청각장애인 관람객 위한 AI 자막안경 아울 활성화 업무협약'(2025.2.18), https://www.etnews.com/20250218000336

[19] Google Cloud, 'Speech-to-Text pricing'(2026.10 확인), https://cloud.google.com/speech-to-text/pricing

[20] SYSTRAN, 'faster-whisper', https://github.com/SYSTRAN/faster-whisper

[21] OpenAI, 'whisper-large-v3-turbo' 모델 카드, https://huggingface.co/openai/whisper-large-v3-turbo

[22] 박정선, '오늘의 자막이, 내일의 문화를 만든다', 데일리안 [언어 장벽 넘는 뮤지컬③](2025.6.22), https://v.daum.net/v/0jfqjwlohP

[23] ㈜오롯플래닛 홈페이지 · 자막 제작 툴, https://orotplanet.com, https://tool.orotplanet.com

[24] 유니스텝(UNISTEP) 예매 · 안내 사이트, https://unistep.imweb.me

[25] J. Brooke, 'SUS: A "quick and dirty" usability scale', Usability Evaluation in Industry, 1996